香港证监会监管文本检索基准

> **HK Financial Regulatory RAG Benchmark — Technical Whitepaper**

作者 Angran Fei • AkuWezInbox@proton.me | **评测对象** 香港证监会《持牌人操守准则》与《基金经理操守准则》全文条款级检索

说 明

本白皮书给出一套可复现的监管文本检索基准：**498 个条款级切块**（覆盖 236 个条款）、**100 道金融合规评测问答**（含 21 道跨条款多 gold 题）、**6 个检索配置横向对比**。
全部指标在 1 vCPU / 3915 MB 内存的云主机上实测产出，
评测程序、语料切块与问答集均随附可逐条回溯至 PDF 原文页码。

一 业务背景与语料

1.1 为什么监管检索的幻觉容忍度为零

香港证监会的《操守准则》与《基金经理操守准则》不是参考读物，而是持牌法团的行为边界。
合规意见书、客户协议条款、专业投资者认定程序，其结论均须落到**具体条款编号**；
引错条款意味着向业务部门发出错误的行为授权，后果不是"答案不够好"，
而是法团在监管审查中无法为自身行为举证。

这与通用问答场景的差别在于**错误的不对称性**：漏检一条相关条款，
后果是合规人员多花时间继续查；错检一条不相关条款却被当作依据，
后果是在错误的法律基础上作出了业务决定。**后者的代价远高于前者**，
因此监管检索系统的首要指标不是"看起来相关"，而是**引用的条款编号是否就是那一条**。
本基准据此以条款级 Recall 与 NDCG 为核心指标，而非以答案文本的相似度为指标。

1.2　切块必须保持语义完整的真实后果

法规条款之间存在前置依赖，脱离依赖单独取用会得出相反结论。
本项目在标注评测集时即遭遇一例：

> **风险提示**
>
> **豁免条款脱离前置程序的误读风险。**
> 《操守准则》15.4 与 15.5 列举了面向企业专业投资者与个人专业投资者**可豁免的条文清单**。
> 若检索系统单独返回 15.4，读者会得到「这些条文对专业投资者不适用」的结论。
> 但 15.4 的适用以 **15.2** 为前置：15.2(a) 要求在豁免生效前取得客户**书面签署的同意声明**、
> **完整说明被视为专业投资者的后果**、并告知客户**有权随时撤回**；
> 15.2(b) 进一步要求**每年执行一次确认程序**。
> **豁免不是无条件的，而是以一整套程序义务为对价。**
> 切块若将 15.2 与 15.4 割裂，检索结果在形式上正确、在合规上危险。
>
> 本项目的切块因此以**条款为最小单元**而非以固定字符数切分：
> 子项 `(a)(b)(i)` 一律归并至所属父条款，超长条款按段落边界分片且不截断句子，
> 并为每一块记录其在 PDF 中的**实际页码**，使任何一条检索结果都可回溯原文核验上下文。

1.3　语料来源

文档	版本	页数	条款单元	切块数
Code of Conduct for Persons Licensed by or Registered with the SFC	2019 年版	211	150	387
Fund Manager Code of Conduct	第三版	36	86	111

两份文档均自证监会官网直接取得，下载时校验 `%PDF` 魔数并记录 SHA-256，无人工转录环节：

文件	字节数	SHA-256（前 16 位）
`sfc_code_of_conduct.pdf`	2,418,947	`7793706166c18bc6…`
`sfc_fund_manager_code.pdf`	701,885	`efdc2d5237da3bed…`

切块后的正文长度中位数为 1002 字符，单块上限 1,400 字符（按段落边界切分，不截断句子）。

1.4 切块流程



图 1 条款级切块流程。第 ② 步与第 ③ 步是语料纯净度的关键：目录页同样含有密集的条款编号，若不显式排除会被识别为正文条款。

1.5 切块版本与数据纯净度

初版切块产出 760 块，经审计发现三项结构性缺陷，均会直接动摇评测有效性：

缺陷	表现	对评测的影响
目录页混入语料	20 个切块的正文形如「Application 39 / [16.2] Interpretation 39」	引入与条款高度相似但无实质内容的噪声文档
条款编号跨段继承	前言段落被标注为条款 20.1	gold 标注失真，检索「命中」与否不可信
编号重复	266 个切块共用 97 个重复 clause_id	条款级命中唯一性丧失，Recall 不可计算

重建后的 v2 语料为 498 块，chunk_id 全局唯一，目录污染为零，
抽样核验 `GP8 Client assets`（p17）、`11.1 Handling of client assets`（p45）、
`12.2 Employee dealings`（p46）、`Sch6 Leveraged foreign exchange trading`（p160）
的条款号、标题与页码与法规原文一致。**本基准的全部指标基于 v2 语料。**

二　评测集

2.1　题型分布

类别	场景	题数	高难度	跨条款多 gold	代表 gold 条款
C1	客户资产隔离与托管	10	2	2	11.1、3.6、3.7、4.1.2
C2	利益冲突与员工交易	10	2	1	10.1、10.2、12.2、16.4
C3	客户身份穿透与 KYC	10	7	4	3.11.1、5.1、5.1A、5.3
C4	专业投资者认定与豁免	10	8	2	15.1、15.2、15.4、15.5
C5	适当性与复杂产品	10	3	1	3.10、3.4、5.2、5.3
C6	利益与收费披露	10	3	1	2.2、2.3、3.11、7.2
C7	保荐人尽职调查	10	8	0	17.10、17.11、17.12、17.13
C8	电子交易、算法交易与另类流动性池	10	8	5	18.10、18.11、18.3、18.4
C9	基金估值、侧袋与运营	10	4	1	5.1、5.2.1、5.2.2、5.3.1
C10	跨条款交叉与穿透式监管	10	10	4	1.11、1.3、11.1、12.5

2.2　标注规则与校验

每题标注 `(doc_id, clause_id)` 形式的 gold 条款，跨条款题标注多个。构建脚本在输出前
逐一校验 gold 条款在语料中真实存在，任一不存在即终止并报错——
100 题全部通过该校验。难度标注中 55 题为高难度，
取自冷门条款（如 20.5 可比 OTC 衍生工具司法管辖区、12.7 专家证人）、
穿透式监管（5.4 指令发出人与实益拥有人）、客户资产隔离与利益冲突等合规实务高频痛点。

标注错误的发现与修正。 存在性校验只能确认 gold 条款存在，无法确认它是否真的回答了该问题。
为此另行计算每题「问题关键词」与「gold 条款正文」的覆盖度，对覆盖度最低的题目逐条回原文复核。
该流程查出三道题的标注指向错误条款：Q037、Q038、Q040 均被标注为 15.4（企业专业投资者豁免条款清单），
但其所问的**同意前披露、撤回权与年度确认程序**实际载于 **15.2**
（原文：`should carry out a confirmation exercise annually`、`has the right to withdraw from being treated as such at any time`）。
三题已更正为 15.2 并重新计分，本文全部指标基于更正后的标注。

> **风险提示**
>
> **评测集由项目作者依据条款索引构建，非第三方公开基准。** 其价值在于标注可逐条回溯至
> 法规原文页码、gold 存在性经程序校验、低覆盖度题目经人工回原文复核，而非在于规模或权威性。
> 跨机构可比的结论需以公开基准复核。

2.3 代表性样题

题号	问题	gold 条款
Q005	What due diligence must a Fund Manager carry out before appointing a custodian?	FMCC 4.2.1・p19、4.2.2・p20
Q017	May a Fund Manager permit relevant persons to deal ahead of client or fund orders?	FMCC 2.1.3・p10
Q024	What is required when characterising whether a client has knowledge of derivatives?	COC 5.1A・p25
Q040	How often must the Professional Investor assessment be reviewed?	COC 15.2・p56
Q043	What obligations apply specifically to complex products?	COC 5.5・p27
Q052	What transaction related information must be disclosed to clients?	COC 8.3A・p41
Q063	What is the scope of a sponsor's due diligence obligation?	COC 17.6・p80
Q078	Who may be given access to an alternative liquidity pool?	COC 19.4・p102
Q085	What must be done before a side pocket is introduced in a fund?	FMCC 5.4.1・p23
Q097	What must be notified to the Commission and in what circumstances?	COC 12.5・p48

每题的 gold 条款均标注其在 PDF 中的实际页码，审阅者可直接翻至该页核对问题与条款是否对应。

三　检索配置与关键决策

六个配置构成一个 **2×2 消融矩阵**（模型尺寸 × 是否融合 BM25）外加两个端点：
纯关键词基线 E，以及在全规格之上追加交叉编码重排的 B。
该设计使「模型尺寸」与「是否融合」两个变量可以分别归因，而非混在一起比较。

配置	检索方式	模型	在消融矩阵中的位置
E	纯关键词	BM25（Okapi）	对照基线
C	纯稠密	bge-small-en-v1.5（384 维）	小模型 × 不融合
D	稠密 + 关键词 RRF 融合	bge-small + BM25	小模型 × 融合
A	纯稠密	bge-m3（1024 维）	大模型 × 不融合
F	稠密 + 关键词 RRF 融合	bge-m3 + BM25	大模型 × 融合
B	稠密召回 + 交叉编码重排	bge-m3 + bge-reranker-v2-m3	精度优先的生产上界

影响结论成立与否的决策记录于架构决策记录（ADR），全文附于第六节：
ADR-001 内存点积与内存 BM25 替代独立向量数据库、**ADR-003** 融合采用 RRF 而非加权相加、

ADR-004 以重排替代增大 top-k、**ADR-005** 评测集统一英文、
ADR-006 分阶段独立进程的评测架构、**ADR-007** 条款级而非切块级的命中判定。

四　实测结果

4.1　检索质量

配置	向量维度	Recall@1	Recall@5	Hit@1	Hit@5	MRR@10	NDCG@5	严格 Recall@5
E　BM25 纯关键词	—	49.83	84.00	56	90	70.50	71.22	78.00
C　bge-small 纯稠密	384	61.17	88.17	70	91	79.18	79.42	85.00
D　bge-small + BM25	384	**66.17**	87.50	75	92	82.56	81.01	83.00
A　bge-m3 纯稠密	1024	64.17	92.17	73	96	82.61	82.95	88.00
F　bge-m3 + BM25	1024	57.67	90.00	66	96	78.23	78.55	84.00
B　bge-m3 + Reranker	1024	65.67	**95.17**	74	98	**84.74**	**85.90**	**92.00**

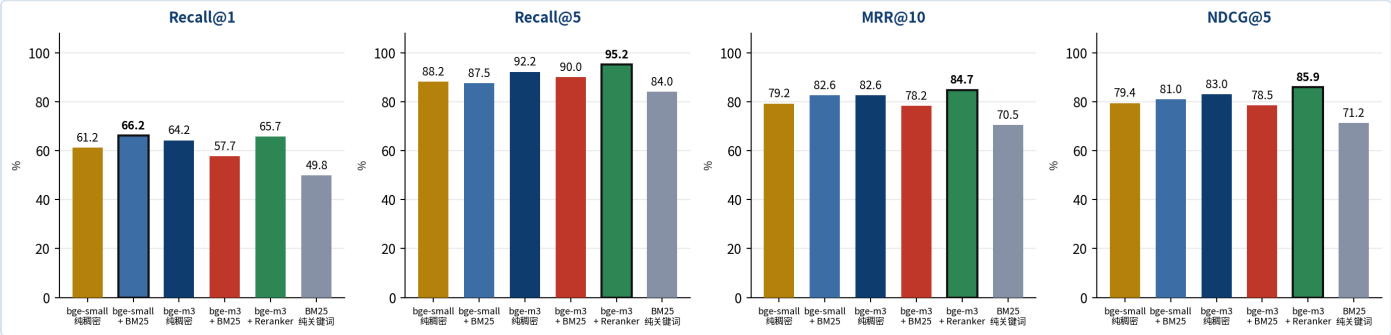


图 2　四项核心指标横向对比。黑框标示该指标的最优配置。

关键词基线并不弱。 BM25 在 Recall@5 上达到 84.00%，原因是监管文本的条款标题与查询用语高度重合（如 “best execution”、“side pocket”、“due diligence”），术语本身即为强检索信号。任何声称稠密检索在法规场景大幅碾压关键词检索的结论，都应先核对基线是否被正确实现。

全规格与轻量档的差距集中在首位命中。 bge-m3（1024 维）相对 bge-small-en-v1.5（384 维）在 Recall@1 上领先 3.00 个百分点，Recall@5 上领先 4.00 个百分点。维度提升主要改善排序质量而非召回覆盖面。

多路融合不是万灵药，其收益取决于两路检索器的强弱是否匹配。 这是本基准最具工程价值的一条结论，由 2×2 消融设计（模型尺寸 × 是否融合 BM25）直接给出：

融合组合	稠密侧单独 Recall@1	融合后 Recall@1	变化
bge-small（384 维）+ BM25	61.17%	**66.17%**	**+5.00**
bge-m3（1024 维）+ BM25	64.17%	**57.67%**	**-6.50**

同一个 BM25（单独 Recall@1 仅 49.83%），融入轻量档使首位命中**提升 5.00 个百分点**，融入全规格档却使其**下降 6.50 个百分点**。根因在于 RRF 只使用排名、不使用分数（见 ADR-003）：当稠密侧显著强于关键词侧时，等权融合让弱侧的错误结果获得与强侧同等的排名权重，把强侧原本正确的首位结果挤出第一名。**因此「上混合检索」不是一个可以无条件照搬的架构决策**——在采用等权 RRF 之前，必须先确认两路召回器的单独表现处于同一量级，否则融合是净损失。

覆盖面与首位命中需分开决策。 融合在 Recall@5 上的表现与 Recall@1 并不同向：轻量档融合后 Recall@5 为 87.50%（单独 88.17%），全规格档融合后为 90.00%（单独 92.17%）。融合提升双路共识条款的排名，代价是少数仅由稠密检索召回的 gold 条款被挤出前五。若下游只取 top-1 交付人工复核，应按 Recall@1 选型；若取 top-k 作为生成端的上下文窗口，应按 Recall@5 与严格 Recall@5 选型。

重排的收益与代价均显著。 交叉编码重排使 Recall@1 提升 1.50 个百分点，但单查询新增约 102.9 秒（CPU，候选池 top-20）。该延迟在 GPU 上可降低一个数量级，但在纯 CPU 部署下已超出交互式查询的可接受范围。

4.2 成本

配置	语料编码耗时	单查询 p50	单查询 p95	进程峰值内存	备注
E　BM25 纯关键词	—	0.8 ms	1.1 ms	34 MB	—
C　bge-small 纯稠密	110 s	31.6 ms	42.4 ms	784 MB	batch=16
D　bge-small + BM25	—	32.4 ms	—	784 MB	RRF k=60，两路各取 top-100
A　bge-m3 纯稠密	1747 s	446.7 ms	5694.0 ms	1,943 MB	batch=4
F　bge-m3 + BM25	—	447.4 ms	—	1,943 MB	RRF k=60，两路各取 top-100
B　bge-m3 + Reranker	—	103,392.7 ms	—	2,267 MB	重排候选池 top-20

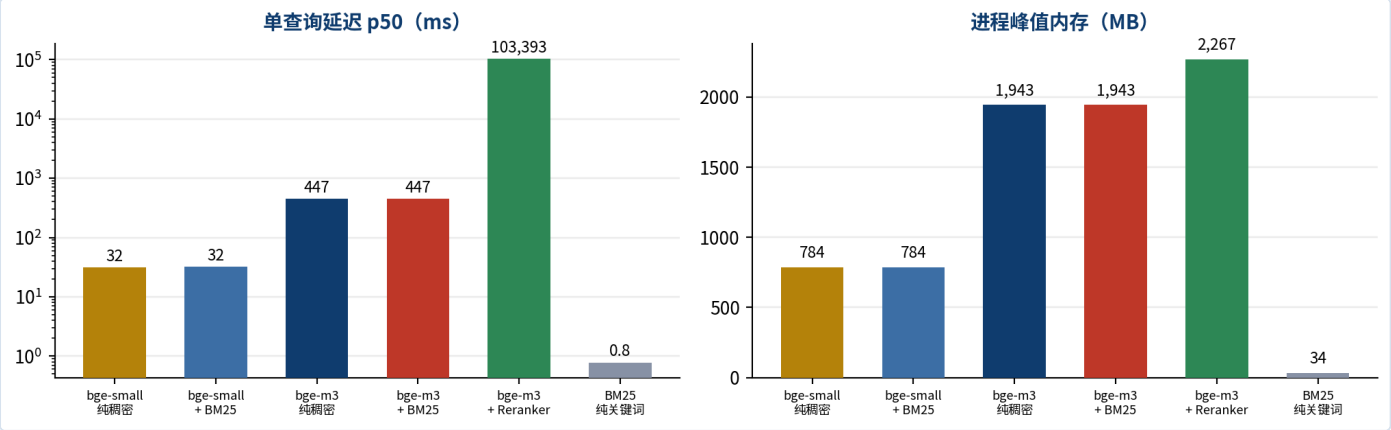


图 3　延迟与内存开销。左图为对数坐标。内存为进程峰值常驻集（RSS），含模型权重与向量索引。

4.3 分类表现

类别	题目场景	bge-m3 + Reranker Hit@5	BM25 Hit@5	差值
C1	客户资产隔离与托管	**100**	90	+10
C2	利益冲突与员工交易	**100**	90	+10
C3	客户身份穿透与 KYC	**90**	70	+20
C4	专业投资者认定与豁免	**100**	100	0
C5	适当性与复杂产品	**90**	100	-10
C6	利益与收费披露	**100**	90	+10
C7	保荐人尽职调查	**100**	100	0
C8	电子交易、算法交易与另类流动性池	**100**	80	+20
C9	基金估值、侧袋与运营	**100**	100	0
C10	跨条款交叉与穿透式监管	**100**	80	+20

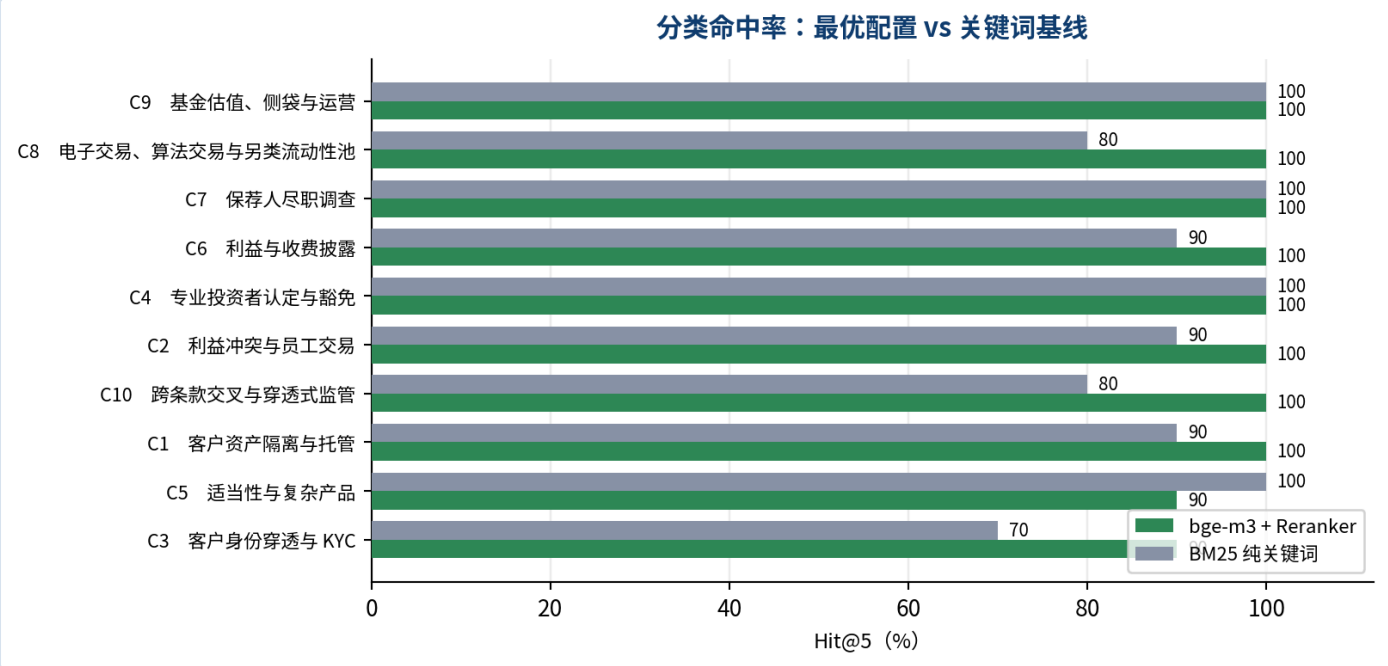


图 4　分类命中率对比。按最优配置的 Hit@5 升序排列，与关键词基线并置。

4.4 失败归因

失败集定义：四个基础配置（BM25 / bge-small / bge-small+BM25 / bge-m3）的 top-5 条款中均无任一 gold 条款。重排配置 B 是对 A 的 top-20 候选重排，A 的候选池若无 gold 条款，B 必然同样未命中，故以四个基础配置界定失败集不会遗漏。

按此定义，100 题中有 **0 题**（0.0%）被全部配置漏检。

单配置独有贡献：共 3 题仅被某一个配置在前五命中——BM25 纯关键词 1 题；bge-m3 纯稠密 2 题。这说明各配置的失败模式并不重合：稠密检索擅长语义改写，关键词检索擅长术语精确匹配，二者的召回集合存在互补空隙。

上述结果的直接含义是：**四个基础配置的并集覆盖率已接近全集**，因此在生产环境中，多路召回取并集再统一排序，其收益可能高于继续增大单一模型的参数量。

五　结论与选型建议

场景	推荐配置	依据
交互式查询（CPU 部署）	bge-small + BM25	Recall@1 **66.17%**（全配置最高）、单查询 32 ms、内存 784 MB
离线批量审阅（精度优先）	bge-m3 + Reranker	Recall@5 **95.17%**、NDCG@5 **85.90%**；单查询 103 s，非实时专用
边缘部署（无 GPU）	BM25 纯关键词	Recall@5 84.00%、延迟 0.78 ms、内存 34 MB，零模型依赖

说　明

本基准的三条可迁移结论。
① 法规文本的条款标题承载了极强的检索信号，关键词基线必须作为对照项实现，
否则容易把「语料本身好检索」误读为「模型效果好」。
② 向量维度的提升主要兑现为排序质量（Recall@1、MRR）而非召回覆盖面（Recall@5），
选型应依据下游是取 top-1 还是 top-k 的上下文窗口而定。
③ 交叉编码重排在 CPU 上的延迟代价是数量级的，其部署可行性由硬件而非效果决定。

风险提示

绝对 Recall 受真实标注的完备性限制，本文的结论建立在横向对比之上。
复核发现，最优配置在 26 道题上的首位检出条款落在 gold 清单之外，
其中约四分之一属于**标注不完整而非检索错误**——例如「将企业客户视为专业投资者前须完成何种评估」
一题检出 15.2，而 gold 标注为 15.4，但前置评估程序恰恰载于 15.2，该检出结果同样成立。
因此**本文的绝对 Recall 数值应被理解为下界，不应作为「准确率」对外引用**。
由于六档配置使用同一套 gold 标注接受评分，
配置之间的横向对比规律不受标注完备性影响，本文的全部结论均建立在该对比之上。

其余已知边界：① 评测集为自建，非第三方公开基准（见 2.2 节）；
② 全部查询为英文，未覆盖中文及中英混合查询场景（见 ADR-005）；
③ 指标为检索质量，未评估生成端的忠实度与引用正确性，该环节需另行以答案级标注评测；
④ 延迟与内存在 1 vCPU 云主机上测得，不代表 GPU 或多核环境下的表现。

六　复现与架构决策记录

6.1　复现步骤

```
pip install -r requirements.txt    # 依赖；PyTorch 建议装 CPU 版以免拉入 CUDA
./run_eval.sh                      # 单一入口：切块 → 六档评测 → 图表 → 正文 → PDF → 质检
```

该脚本串联的完整阶段为：

```
corpus/fetch.py        取原文 PDF，校验 %PDF 魔数与 SHA-256
src/chunk2.py          条款级切块                  → data/chunks_v2.jsonl
data/build_eval_set.py 评测集 + gold 存在性校验    → data/eval_set_100.json
data/audit_eval_set.py 标注体检：覆盖度排序，低覆盖题回原文复核
src/eval_rag_cpu.py    bm25 → small → hybrid → m3 → hybridm3 → rerank → merge
                       （每阶段独立进程，排名矩阵落盘，见 ADR-006）
src/analyze_failures.py  失败归因                  → results/failure_analysis.json
src/make_figs.py / gen_whitepaper.py / build_pdf.py / verify_whitepaper.py
```

模型权重置于 `./models/` 或以环境变量 `MODEL_DIR` 指向，代码内无绝对路径。
标注修正后执行 `./run_eval.sh rescore`：该模式复用已落盘的排名矩阵重算全部指标，
无需重新编码语料（可省去 bge-m3 约 29 分钟的编码开销）。

执行环境：1 vCPU ／ 3915 MB 物理内存 ／
4095 MB Swap ／ PyTorch 2.14.1+cpu（CPU）／ Python 3.11.2。
模型权重为 BAAI 官方发布的 `bge-small-en-v1.5`、`bge-m3`、`bge-reranker-v2-m3`。

6.2　架构决策记录

ADR-001　在轻量监管法规场景下采用 NumPy 内存点积与内存 BM25，替代独立向量数据库

背景　语料为两部香港证监会法规，切块后共 498 个条款级单元。 全规格配置下向量规模为 498 × 1024 维 float32，约 **2.0 MB**； 轻量档 498 × 384 维约 **0.75 MB**。关键词检索侧的倒排索引量级与之相当。 项目早期曾规划以 pgvector 承载向量检索、以 Postgres `tsvector` 承载全文检索。

决策　向量检索以 **NumPy 内存点积**实现（向量 L2 归一化后，相似度即单次矩阵乘）； 关键词检索以 **内存 BM25（rank_bm25 Okapi）** 实现。 不引入 pgvector、Elasticsearch 或任何托管向量服务。

理由　**① 规模决定架构。** 2 MB 量级的向量全部驻留内存，单次全量点积在 1 vCPU 上耗时低于毫秒级； 近似最近邻索引（HNSW/IVF）的存在意义是在百万级向量上以召回率换延迟， 在 498 条上它只会引入召回损失而没有任何延迟收益。 **② 延迟构成的真实分布。** 实测单查询 p50 延迟中， 轻量档 31.57 ms、全规格档 446.66 ms，其中绝大部分是**查询文本的编码耗时**， 检索本身（点积 + 排序）不构成瓶颈。引入外部向量库无法改善主要矛盾， 反而新增一次网络往返。 **③ 冷启动与零运维。** 内存方案无需建库、无需迁移、无需维护连接池与扩展版本， 进程启动即可用；评测的分阶段独立进程架构（ADR-006）也要求各阶段能独立冷启动， 外部有状态依赖会与该设计冲突。 **④ 部署复杂度与可审计性。** 整条检索链仅依赖 Python 标准库、NumPy 与 rank_bm25， 可在内网离线环境完整复现；审计方无需理解数据库 schema 即可核对检索逻辑。 对金融机构而言，可审计性本身即为交付要求。

后果　本方案的适用边界明确：**语料规模增长至十万级切块时，内存点积的线性扫描将成为瓶颈**， 届时应切换至带 ANN 索引的向量库，并重新评估召回率损失。 本基准不提供该规模下的实测数据。 另需注意：内存方案不具备跨进程共享索引的

能力， 多副本部署时每个副本需各自持有一份向量，内存占用随副本数线性增长。

ADR-003　多路融合采用 RRF 而非加权分数相加

背景　稠密检索输出余弦相似度（有界 0–1），BM25 输出无上界的 ts_rank 类分值， 两者量纲不可直接相加。

决策　采用倒数排名融合（Reciprocal Rank Fusion）：`score = Σ 1 / (k + rank_i)`，k = 60， 两路各取 top-100 参与融合。

理由　加权分数相加必须先归一化，而归一化系数本身是一个需要调优的超参， 且对查询分布敏感——在一套 100 题的评测集上调出的系数不具备可迁移性。 RRF 只使用**排名**不使用**分数**，天然免疫量纲问题，且无需调参。

后果　**RRF 丢弃分数强度信息，这一代价在本基准中被实测量化。** 两路检索器强弱匹配时融合有增益，不匹配时融合有损害： | 融合组合 | 稠密侧单独 Recall@1 | 融合后 Recall@1 | 变化 | |---|---|---|---| | bge-small (384 维) + BM25 | 61.17% | **66.17%** | **+5.00** | | bge-m3 (1024 维) + BM25 | 64.17% | **57.67%** | **−6.50** | BM25 单独的 Recall@1 为 49.83%。当稠密侧显著强于关键词侧时， 等权 RRF 使弱侧的错误结果获得与强侧同等的排名权重， 将强侧原本正确的首位结果挤出第一名。 **因此 RRF 的等权假设是一项前提条件，而非普适最优**； 若需在强弱悬殊的两路间融合，应改用带可学习权重的融合或级联式召回。

ADR-004　以交叉编码重排替代单纯增大 top-k

背景　提升召回覆盖面有两条路径：直接增大返回条数 k，或在粗排之上追加精排。

决策　保持下游上下文窗口为 top-5，在其之上以 bge-reranker-v2-m3 对稠密召回的 top-20 候选池做交叉编码重排。

理由　单纯增大 k 的三项代价：① 挤占下游大模型的上下文预算； ② 引入低相关片段，反而降低生成答案的忠实度；③ 延迟随 k 线性增长。 重排以一次小模型推理换取排序质量，使下游在同样的 5 条预算内获得更高相关度。

后果　**收益与代价均已实测量化。** 相对 bge-m3 纯稠密： | 指标 | 纯稠密 | + 重排 | 变化 | |---|---|---|---| | Recall@1 | 64.17% | 65.67% | +1.50 | | Recall@5 | 92.17% | **95.17%** | +3.00 | | NDCG@5 | 82.95% | **85.90%** | +2.95 | | 严格 Recall@5 | 88.00% | **92.00%** | +4.00 | | 单查询 p50 延迟 | 446.66 ms | **103,392 ms** | ×231 | 在 1 vCPU 环境下重排使单查询延迟升至约 103 秒， **其部署可行性由硬件而非效果决定**：该配置适用于离线批量审阅， 不适用于交互式查询。GPU 环境下该延迟可降低约一个数量级， 但本基准未在 GPU 上实测，不提供该数值。

ADR-005　评测集统一使用英文

背景　语料为香港证监会英文法规原文（《持牌人操守准则》《基金经理操守准则》）。 评测需对比多语种模型 bge-m3 与英文单语模型 bge-small-en-v1.5。

决策　100 题评测集全部以英文撰写。

理由　bge-small-en-v1.5 为英文单语模型。若以中文出题，该档成绩将因语种不匹配而系统性偏低， 得到的差距无法区分「模型容量差异」与「语种覆盖差异」，使双模对比结论不成立。 统一英文可将变量收敛为检索能力本身。香港持牌法团合规人员查阅 SFC 条文亦以英文为主， 英文查询符合真实使用场景。

后果　本基准不反映跨语种检索能力。中文查询场景下 bge-m3 的多语种优势未被测量， 如需评估应另建中英对照评测集，并作为独立实验报告。

ADR-006　分阶段独立进程的评测架构

背景　评测执行环境为 1 vCPU、约 1.5 GB 可用物理内存、3.6 GB Swap 的云主机。 bge-m3 与 bge-reranker-v2-m3 的 fp32 权重各约 2.2 GB。

决策　评测拆分为 bm25 / small / hybrid / m3 / rerank / merge 六个阶段， 每阶段为独立进程，中间排名以 `.npy` 落盘，最终由 merge 阶段汇总。

理由　单进程内连续加载两个 2.2 GB 模型将超出可用内存，触发 OOM。 Python 进程内 `del` 与 `gc.collect()` 不保证将内存归还操作系统， 只有进程退出才能完整释放。分阶段架构同时带来两项工程收益： 任一阶段失败可单独重跑而不必重算全部；各阶段峰值内存可独立测量并归因。

后果　阶段间需通过磁盘交换中间结果，引入少量 I/O 开销（排名矩阵为 100×200 int32，可忽略）。 `hybrid` 与 `rerank` 阶段依赖前序阶段的落盘产物，执行顺序不可调换。

ADR-007　条款级而非切块级的命中判定

背景　一个法规条款（如 Schedule 4、17.6 Due diligence）因篇幅较长会被切分为多个切块。 评测集的 gold 标注为条款编号，而非具体切块。

决策　检索结果先由切块排名折叠为条款排名（同一 clause_id 取其最佳名次，去重保序）， 再计算 Recall@k / Hit@k / MRR / NDCG。

理由　若按切块判定，同一条款的多个切块会重复占据排名前列， 使 Recall@5 虚高且无法反映「是否找到了正确条款」这一真实业务目标。 合规人员的诉求是定位到条款，而非定位到某个切块。

后果　切块粒度的差异（长条款切得更碎）不再直接影响指标， 各配置在同一折叠规则下可比。副作用是无法评估切块内部的定位精度， 该维度需另行以答案片段级标注评测。

Angran Fei · AkuWezInbox@proton.me | 语料切块、评测集、评测程序与本文全部指标可复现；每个切块均标注 PDF 页码以供回溯原文。